

研究点一：面向分布式 NUMA 的 LP-LT-MT 层级化资源抽象模型

- **存在的问题：** 分布式 NUMA (D-NUMA) 环境中，物理内存分布极其分散且具有显著的访问非均匀性。现有的分布式共享内存 (DSM) 模型存在两个极端：要么通过编译器强行拉平物理差异（如 PGAS），导致开发者难以进行局部性优化；要么抽象粒度过粗，缺乏对底层硬件（如 RDMA 网卡、PCIe 总线）的进程级管控，导致在高并发访问时产生严重的硬件资源竞争。
- **目前的研究现状：**
 - **Nu (NSDI '23) & Quicksand (NSDI '25)：** 提出了 **Procllet (逻辑单元)** 抽象，其核心是通过计算流的**迁移 (Migration)** 来实现集群资源的弹性收割。
 - **局限性：** 这类研究的重心在于“资源利用率”，而非“极致访存性能”。在内存密集型场景下，由于模糊了操作系统进程 (Process) 的边界，导致逻辑单元直接冲击硬件资源，缺乏一个有效的代理层级来对网卡门铃 (Doorbell) 和内存访问进行统一管理与隔离。
- **我们是怎么研究的：** 提出 **LP-LT-MT 三层解耦架构**，建立逻辑与物理的精准映射：
 1. **LP (Logical Process)：全局逻辑层。** 负责构建全局虚拟地址空间 (GVA)，提供透明的单机化编程视图。
 2. **LT (Logical Thread)：节点实例层 (对应 OS 进程)。** 作为任务在物理节点上的代理管家，垄断网卡句柄，负责管理该节点的内存分片。
 3. **MT (Micro-thread)：轻量执行层。** 运行在 LT 内部的用户态执行流，负责具体的算法逻辑。
- **创新性与解决的问题：**

建立进程级资源代理机制，降低硬件访问竞争开销：

- **解决的问题：** 在高性能访存场景下，海量并发流若直接操作 RDMA 硬件，会引发网卡门铃寄存器 (Doorbell) 的频繁竞争。这种竞争会导致硬件层面的指令排队，显著增加访问延迟，并降低 PCIe 总线的有效带宽利用率。
- **创新点：** 通过 LT (操作系统进程级实例) 独占网卡硬件句柄，实现了对物理资源的**单点管控**。LT 充当了所有微线程 (MT) 的通信网关，将 MT 产生的离散访存请求在用户态空间进行预处理。这种设计将原有的“硬件级多对多竞争”转化为“软件级多对一聚合”，规避了网卡在高并发下的性能雪崩。

研究点二：基于 LT 代理聚合的去中心化缓存一致性协议

- **存在的问题：** 在 D-NUMA 系统中，大规模并行访存面临**协议瓶颈**与**硬件开销**的双重挑战。首先，传统协议依赖中心化目录管理内存状态，在高并发写冲突下会产生严重的通信瓶颈；其次，微观执行流 (MT) 产生的细碎访存请求会引发海量的 RDMA 小包，导致网卡门铃溢出和 PCIe 总线效率极低。
- **目前的研究现状：**
 - **GAM (VLDB '18)：** 典型的 RDMA 分布式共享内存系统。其核心是使用**中心化目录 (Directory)** 维护全局一致性。
 - **局限性：** 中心目录在多机写竞争场景下扩展性差。同时，由于缺乏**请求代理聚合**，每个访存操作都独立触发网络 I/O，无法保护底层硬件免受高频小包的冲击。
 - **FaRM (SOSP '15)：** 利用 RDMA 原子操作实现乐观并发控制，但主要针对规则的对象事务，无法高效处理非规则的原始内存地址访存。
- **我们是怎么研究的：** 研究基于 **LT 代理的去中心化一致性机制**：

1. **去中心化目录**：将一致性元数据按地址范围均匀分布到各个 LT 实例（Home Node），利用 RDMA 原子操作（CAS/Fetch-and-Add）实现状态的去中心化判定与更新。
 2. **请求代理聚合**：由 LT 进程拦截内部所有 MT 的访存请求，在用户态缓冲区将其聚合为批量指令链（Verb List）下发。
- **创新性与解决的问题**：
 1. **消除单点瓶颈**：通过 Home Node 分布式化设计，解决了 GAM 在大规模并发下的扩展性限制。
 2. **硬件感知优化**：通过 LT 代理层的聚合，保护了物理网卡免受高频冲击，显著提升了跨节点访存的有效带宽。

研究点三：感知访存延迟的用户态微线程（MT）自适应调度机制

- **存在的问题**：分布式网络延迟（约 $3\mu s$ ）是 D-NUMA 系统中不可避免的性能损耗。如果调度器不具备对网络状态的感知能力，CPU 在等待远端数据返回时会陷入长期的空转（Stall）。传统的操作系统线程切换代价远高于网络延迟，无法起到填补空洞的作用；而固定的并发度难以适应动态波动的网络环境。
- **目前的研究现状**：
 - **Nu & Quicksand**：主要采用**迁移（Migration）**手段。即通过搬迁计算流来接近数据。
 - **局限性**：在数据密集型场景中，搬迁庞大的执行栈（Stack）状态往往代价高昂且难以应对多点散落的数据访存。
 - **Caladan (NSDI '19)**：实现了极致的用户态调度。其局限在于主要处理单机内负载，**不感知分布式网络 RTT 的波动**，无法根据实时跨机延迟调整并发掩盖深度。
- **我们是怎么研究的**：研究基于**延迟感知的自适应 MT 调度算法**：
 1. **极低开销切换**：设计 10ns 级的 MT 上下文切换逻辑，确保调度器有足够的空间去填补微秒级的 RTT 空洞。
 2. **自适应掩盖策略**：LT 实时测量远端 RTT 波动，动态调整处于活跃状态的 MT 数量（掩盖水位线），实现计算与通信在时间轴上的极致重叠。
- **创新性与解决的问题**：
 1. **“原地”延迟掩盖**：不同于 Nu 的任务迁移，本研究通过“原地高并发切换”解决了掩盖延迟的问题，避开了复杂的跨机状态同步。
 2. **时延感知调度**：LT 进程实时监测与远端节点通信的平均往返时延（RTT），并根据该参数**动态计算并调整活跃微线程（MT）的数量**。